

Aprendizaje Automático Tarea #2 Clasificador Bayesiano Ingenuo

① Generos: Un programa de salud gubernamental desea clasificar los registros de las personas en géneros femenino (F) y masculino (M) a partir de los atributos nombre, estatura y peso. Se cuentan con los sig. registros.

Nombre	Estatura (m)	Peso (kg)	Género
Denis	1.72	75.3	M
Guadalupe	1.82	81.6	M
Alex	1.80	86.1	M
Alex	1.70	77.1	M
Cris	1.73	78.2	M
Juan	1.80	74.8	M
Juan	1.80	74.3	M

Denis	1.50	50.5	F
Alex	1.52	45.3	F
Cris	1.62	61.2	F
Rene	1.67	68.0	F
Guadalupe	1.65	58.9	F
Guadalupe	1.75	68.0	F

Entrena un clasificador bayesiano ingenuo usando estimación por máxima verosimilitud y otro usando estimación por máximo a posteriori. Reporta los parámetros que obtuviste en ambos casos y usa los clasificadores entrenados para predecir la clase de los sig. vectores: $x_1 = (\text{Rene}, 1.68, 65)$, $x_2 = (\text{Guadalupe}, 1.75, 80)$, $x_3 = (\text{Denis}, 1.80, 79)$, $x_4 = (\text{Alex}, 1.90, 85)$ y $x_5 = (\text{Cris}, 1.65, 70)$. Describe detalladamente el procedimiento que seguiste tanto en el entrenamiento como en la predicción y discutir los resultados obtenidos. Para el entrenamiento del clasificador por máximo a posteriori, considerar los sig. valores para las distribuciones correspondientes

Género	Nombre	Estatura			Peso		
		μ_0	σ_0^2	σ^2	μ_0	σ_0^2	σ^2
M	21 + k	1.7	0.3	0.0020	85.5	17.0	15.76
F	21 + k	1.5	0.1	0.0074	70.3	85.0	71.00

A ojo meteo x_2, x_3, x_4 pertenecen a la clase M; x_5 y x_1 podrían ser F. Sólo de ver los datos. Veamos si es "verdad".

- Estimación por máxima verosimilitud:

Def. (verosimilitud - muestra observada) Sea X_1, \dots, X_n muestra aleatoria (m.a.) de un modelo con densidad $f_X(x; \theta)$ y $\theta \in \Theta$ un parámetro desconocido, definimos la función de verosimilitud $\ell: \Theta \rightarrow \mathbb{R}$ como:

$$\ell(\theta; \underline{x}) := f_{\underline{X}}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i; \theta)$$

Primero asumimos una distribución de probabilidad para cada uno de los atributos. Para este caso la estatura y el peso los asumimos como distribuciones normales $N(\theta, \sigma^2)$. Mientras que el nombre lo modelamos como una categorica $\text{Cat}(x; \bar{\pi})$. Por estabilidad numérica usaremos la Estatura en cm.

Entrenamiento: Tenemos la siguiente tabla (calculada en excel)

Género	μ_p (media peso) (kg)	σ_p^2	μ_A (media altura) (cm)	σ_A^2
M	78.2	15.7657	176	2.02×10^3
F	58.6	71.009	161.8	7.94×10^3

Ahora bien; El clasificador bayesiano está dado por

$$\hat{y} = \underset{k \in \{1, \dots, K\}}{\operatorname{argmax}} [P(C_k) \prod_{i=1}^n P(x_i | C_k)]$$

Para el caso de las características categóricas tenemos que

Características: $[\vec{x}]_{\alpha} \in \{f_1, f_2, \dots, f_{k_{\alpha}}\}$: cada característica α cae dentro de una de las k_{α} categorías.

$$P(x_{\alpha} = j | y = c) = [\theta_{jc}]_{\alpha} \text{ y } \sum_{j=1}^{k_{\alpha}} [\theta_{jc}]_{\alpha} = 1$$

donde $[\theta_{jc}]_{\alpha}$ es la probabilidad de que la caract. α tenga el valor j dado que la etiqueta es c y la restricción indica que x_{α} debe tener una de las categorías $\{1, \dots, k_{\alpha}\}$

La estimación de parámetros se hace como:

$$[\hat{\theta}_{jc}] = \frac{\sum_{i=1}^n I(y_i = c) I(x_{i\alpha} = j) + L}{\sum_{i=1}^n I(y_i = c) + L k_{\alpha}}$$

Donde $x_{i\alpha} = [\vec{x}_i]_{\alpha}$ y L es un parámetro de suavizado. Si $L=0$ tenemos MVE, si $L>0$ tenemos MAP. Si $L=1$ obtenemos el suavizado de Laplace

En palabras: $[\hat{\theta}_{jc}] = \frac{\# \text{muestras con etiqueta } c \text{ que tienen la caract } \alpha \text{ con valor } j}{\# \text{muestras con la etiqueta } c}$

Predicción: $\underset{y}{\operatorname{argmax}} (P(y=c | \vec{x})) \propto \underset{y}{\operatorname{argmax}} \hat{\pi}_c \prod_{\alpha=1}^d [\hat{\theta}_{jc}]_{\alpha}$

Extracto tomado de: www.cs.cornell.edu/courses/cs4780/2018sp/lectures/lecturenote05.html

Dadas las condiciones de independencia de Naive Bayes para calcular \hat{y} basta con calcular los estimadores de cada distribución y después multiplicarlas entre sí

- Estimación para la normal de las estaturas:

sabemos que para la normal $\hat{\mu}_{MVE} = \frac{1}{n} \sum_{i=1}^n x^{(i)}$ y $\hat{\sigma}_{MVE}^2 = \frac{1}{n} \sum_{i=1}^n (x^{(i)} - \hat{\mu}_{MVE})^2$

$\hat{\mu}_{MVE}^{(hombre)} = \frac{1}{7} (172+182+180+170+173+180+180) = 176.71 \approx 177$. \rightarrow ya lo había calculado

$\hat{\mu}_{MVE}^{(mujer)} = \frac{1}{6} (150+152+162+167+165+175) = 161.8 \approx 162$

$\hat{\sigma}_{MVE}^{2(h)} = \frac{1}{7} [(172-177)^2 + (182-177)^2 + (180-177)^2 + (170-177)^2 + (173-177)^2 + (180-177)^2 + (180-177)^2]$
 $= \frac{1}{7} [25 + 25 + 9 + 49 + 16 + 9 + 9] = \frac{142}{7} = 20.28 \approx 20$

$$\hat{\sigma}_{MVEA}^{2(mujer)} = \frac{1}{6} [(150-162)^2 + (152-162)^2 + (162-162)^2 + (167-162)^2 + (165-162)^2 + (175-162)^2]$$

$$= \frac{1}{6} [144 + 100 + 0 + 25 + 9 + 169] = 74.5 \approx 74$$

- Estimación para la normal de los pesos:

$$\hat{\mu}_{MVEP}^{(hombre)} = \frac{1}{7} (75.3 + 81.6 + 86.1 + 77.1 + 78.2 + 74.8 + 74.3) = 78.2$$

$$\hat{\sigma}_{MVEP}^{2(hombre)} = \frac{1}{7} [(75.3-78.2)^2 + (81.6-78.2)^2 + (86.1-78.2)^2 + (77.1-78.2)^2 + (78.2-78.2)^2 + \dots$$

$$\dots + (74.8-78.2)^2 + (74.3-78.2)^2] = \frac{1}{7} [8.41 + 11.56 + 62.41 + 1.21 + 0 + 11.56 + 15.21]$$

$$= \frac{1}{7} [110.36] = 15.766 = 15.8$$

$$\hat{\mu}_{MVEP}^{(mujer)} = \frac{1}{6} (50.5 + 45.3 + 61.2 + 68.0 + 58.9 + 68.0) = 58.65 = 58.6$$

$$\hat{\sigma}_{MVEP}^{2(mujer)} = \frac{1}{6} [(50.5-58.6)^2 + (45.3-58.6)^2 + (61.2-58.6)^2 + (68.0-58.6)^2 + (58.9-58.6)^2 + (68.0-58.6)^2]$$

$$= \frac{1}{6} [(65.61 + 176.89 + 6.76 + 88.36 + 0.09 + 88.36)] = \frac{1}{6} (426.07) = 71.011 = 71.0$$

- Estimación para la categórica:

$L=0$ ya que es la estimación máxima verosimilitud

$$[\hat{\theta}_{hombreTenis}] = \frac{1}{2} ; [\hat{\theta}_{hombreGrad}] = \frac{1}{3} ; [\hat{\theta}_{hAle}] = \frac{2}{3} ; [\hat{\theta}_{hCns}] = \frac{1}{2}$$

$$[\hat{\theta}_{hJuan}] = \frac{2}{2} = 1 ; [\hat{\theta}_{mDens}] = \frac{1}{2} ; [\hat{\theta}_{mAle}] = \frac{1}{3} ; [\hat{\theta}_{mCns}] = \frac{1}{2} ; [\hat{\theta}_{mPere}] = 1$$

$$[\hat{\theta}_{mGrad}] = \frac{2}{3} ; [\hat{\theta}_{mJuan}] = [\hat{\theta}_{mRene}] = 0 \text{ ya que según los datos no hay mujeres que se llamen Juan y no hay hombres que se llamen Rene}$$

Y con esto ya podemos construir nuestro clasificador bayesiano

$$P(hombre | \vec{x}) \propto \left[\frac{1}{\sqrt{2\pi} \hat{\sigma}_{MVEP}^{2(h)}} \exp\left(-\frac{(x_i^{(p)} - \hat{\mu}_{MVEP}^{(h)})^2}{2 \hat{\sigma}_{MVEP}^{2(h)}}\right) \right] \left[\frac{1}{\sqrt{2\pi} \hat{\sigma}_{MVEA}^{2(h)}} \exp\left(-\frac{(x_i^{(A)} - \hat{\mu}_{MVEA}^{(h)})^2}{2 \hat{\sigma}_{MVEA}^{2(h)}}\right) \right] \dots$$

$$\dots * [\hat{\theta}_{hombre} x_i^{(cat)}] [P(hombre)] \dots (1)$$

$$P(mujer | x_i) \propto \left[\frac{1}{\sqrt{2\pi} \hat{\sigma}_{MVEP}^{2(m)}} \exp\left(-\frac{(x_i^{(p)} - \hat{\mu}_{MVEP}^{(m)})^2}{2 \hat{\sigma}_{MVEP}^{2(m)}}\right) \right] \left[\frac{1}{\sqrt{2\pi} \hat{\sigma}_{MVEA}^{2(m)}} \exp\left(-\frac{(x_i^{(A)} - \hat{\mu}_{MVEA}^{(m)})^2}{2 \hat{\sigma}_{MVEA}^{2(m)}}\right) \right] \dots$$

$$\dots * [\hat{\theta}_{mujer} x_i^{(cat)}] [P(mujer)] \dots (2)$$

¿Topaste ese abuso de notación? ☹

$x_i^{(p)}$ es la componente correspondiente a p del vector de entrada \vec{x}

(No soy bueno con la notación) ☹

Testing: Ahora si, sea la entrada $\vec{x}_1 = (\text{Rene}, 168, 65)$

$\hat{\theta}_{\text{hombre Rene}}$

$$P(h|\vec{x}_1) = \left[\frac{1}{\sqrt{2\pi}(15.8)} \exp\left(-\frac{(65-78.2)^2}{2(15.8)}\right) \right] \left[\frac{1}{\sqrt{2\pi}(20)} \exp\left(-\frac{(168-177)^2}{2(20)}\right) \right] \begin{bmatrix} 0 \end{bmatrix} \begin{bmatrix} \frac{7}{13} \end{bmatrix} = 0$$

a partir de aquí no anotaré todo, porque si no acabo hasta mañana

$$P(m|\vec{x}_1) = \left[(0.047) \exp\left(-\frac{(65-58.6)^2}{142}\right) \right] \left[(0.046) \exp\left(-\frac{(168-162)^2}{148}\right) \right] \begin{bmatrix} 1 \end{bmatrix} \begin{bmatrix} \frac{6}{13} \end{bmatrix} = \dots$$

$$= (0.047)(0.749)(0.046)(0.784)(1)(0.462) = 5.86 \times 10^{-4}$$

Por lo que \vec{x}_1 es mujer

$$\vec{x}_2 = (\text{Guadalupe}, 1.75, 80)$$

$$P(h|\vec{x}_2) = 0.00131$$

$$P(m|\vec{x}_2) = 8.57 \times 10^{-6}$$

Por lo que \vec{x}_2 es hombre

$$\vec{x}_3 = (\text{Dennis}, 180, 79)$$

$$P(h|\vec{x}_3) = 0.001886$$

$$P(m|\vec{x}_3) = 3.028 \times 10^{-6}$$

Por lo que \vec{x}_3 es hombre

$$\vec{x}_4 = (\text{Alex}, 190, 85)$$

$$P(h|\vec{x}_4) = 1.08 \times 10^{-5}$$

$$P(m|\vec{x}_4) = 1.248 \times 10^{-8}$$

Por lo que \vec{x}_4 es hombre

$$\vec{x}_5 = (\text{Cris}, 165, 70)$$

$$P(h|\vec{x}_5) = 7.843 \times 10^{-6}$$

$$P(m|\vec{x}_5) = 1.909 \times 10^{-4}$$

Por lo que \vec{x}_5 es mujer

Veamos que para este caso la clasificación está muy restringida por el parámetro $[\hat{\theta}_{jc}]$ ya que si al clasificador se le pasa un vector \vec{x} tal que $x_i^{(cat)}$ contiene un nombre que no estaba en nuestros datos de entrenamiento el clasificador no dará ninguna clasificación ya que $P(h|\vec{x}) = P(m|\vec{x}) = 0$ pues $[\hat{\theta}_{hc}] = [\hat{\theta}_{mc}] = 0$

Es decir obtenemos una indeterminación, luego nuestro clasificador sólo servirá para entradas \vec{x} cuyo $x_i^{(cat)}$ nuestro clasificador conoce. Por otro lado si alguna de las clases tiene un nombre que la otra no (como Rene o Juan) entonces el clasificador asignará cualquier vector de entrada, cuyo nombre coincide con el que ya se mencionó, a la clase que tiene dicho nombre sin importar los otros parámetros

Por ejemplo si yo le doy $\vec{x} = (\text{Rene}, 177, 78.2)$ el clasificador dirá que es mujer aún cuando su altura y peso sean las características de un hombre.

Para esta parte concluimos que la variable categórica es muy mala para este modelo ya que si queremos realizar una buena clasificación necesitamos tener datos para todos los nombres y que en el caso de nombres que pueden ser de hombre y mujer (como Guadalupe) se tengan en ambas clases. Si es el caso, entonces es buena esta variable ya que permitiría ahorrar cálculos para cuando las entradas tengan nombres únicos de cada clase (como Juan y Juana). Aunque esto no asegura que la clasificación sea perfecta.

Con respecto a los parámetros no hay mucho que discutir. Los datos de entrenamiento muestran una clara división de las clases por esta razón puede adivinar las salidas sin hacer cálculos sería más interesante ver valores más cercanos.

El suavizado de Laplace arreglará uno de los problemas de la categórica (ejemplo de $\vec{x} = (\text{Rene}, 177, 78.2)$) pero no la falta de datos en cuanto a los nombres. Veámoslo.

Dado que ahora hacemos el máximo a posteriori MAP nuestros estimadores serán:

$$[\hat{\theta}_{jc}] = \frac{\sum_{i=1}^n I(y_i=c) I(x_{ia}=j) + L}{\sum I(y_i=c) + L K_a} \quad \text{donde } L = \alpha_k \text{ de la tabla; } L=1 \text{ } \forall \text{ categorías}$$

$$\hat{\mu} = \frac{\sigma_0^2 \left(\sum_{i=1}^n x^{(ii)} \right) + \sigma^2 \mu_0}{\sigma_0^2 n + \sigma^2}$$

En la etapa de aprendizaje basta calcular $\hat{\mu}$ para la altura y peso y $[\hat{\theta}_{jc}]$ para la categórica, esto se hace usando la tabla y los datos.

Para la altura:

$$\hat{\mu}_{MAP}^{(hombre)} = \frac{(0.002)(1.7) + 0.3(12.37)}{(0.3)(7) + 0.002} = \frac{0.0034 + 3.711}{2.1 + 0.002} = \frac{3.7144}{2.102} = 1.767^m = 176.7 \text{ cm}$$

$$\hat{\mu}_{MAP}^{(mujer)} = \frac{(0.1)(9.71) + (0.0074)(1.5)}{(0.1)(6) + 0.0074} = \frac{0.971 + 0.0111}{0.6 + 0.0074} = \frac{0.9821}{0.6074} = 1.617^m = 161.7 \text{ cm}$$

Para el Peso:

$$\hat{\mu}_{MAP}^{(hombre)} = \frac{(17)(547.4) + (15.76)(85.5)}{(17)(7) + 15.76} = 79.054 = 79.05 \text{ kg}$$

$$\hat{\mu}_{MAP}^{(mujer)} = \frac{(85)(351.9) + (71)(70.3)}{(85)(6) + 71} = 60.074 = 60.07 \text{ kg}$$

El MAP de la categorica es $[\hat{\theta}]_{jc} = \frac{C_k + \alpha_k - 1}{n + \sum_{k=1}^K \alpha_k - K}$
y para este caso $K=5$; $\sum_{k=1}^5 \alpha_k = (2)5 = 10$

$$[\hat{\theta}_{hDennis}]_{MAP} = \frac{1+2-1}{2+10-5} = \frac{2}{7}; [\hat{\theta}_{hGuad}]_{MAP} = \frac{1+2-1}{3+10-5} = \frac{2}{8}; [\hat{\theta}_{hAlex}]_{MAP} = \frac{2+2-1}{3+10-5} = \frac{3}{8}$$

$$[\hat{\theta}_{hCris}]_{MAP} = \frac{1+2-1}{2+10-5} = \frac{2}{7}; [\hat{\theta}_{hJuan}]_{MAP} = \frac{2+2-1}{2+10-5} = \frac{3}{7}; [\hat{\theta}_{hPere}]_{MAP} = \frac{0+2-1}{1+10-5} = \frac{1}{6}$$

$$[\hat{\theta}_{mDennis}]_{MAP} = \frac{1+2-1}{2+10-5} = \frac{2}{7}; [\hat{\theta}_{mGuad}]_{MAP} = \frac{2+2-1}{3+10-5} = \frac{3}{8}; [\hat{\theta}_{mAlex}]_{MAP} = \frac{1+2-1}{3+10-5} = \frac{2}{8}$$

$$[\hat{\theta}_{mCris}]_{MAP} = \frac{1+2-1}{2+10-5} = \frac{2}{7}; [\hat{\theta}_{mPere}]_{MAP} = \frac{1+2-1}{1+10-5} = \frac{2}{6}$$

Aquí termina el entrenamiento

Las funciones predictivas serán:

$$P(\text{hombre} | \vec{x}) = \mathcal{N}_{\text{Peso}}^{(h)}(\mu_p, \sigma_p^2) * \mathcal{N}_{\text{altura}}^{(h)}(\mu_p, \sigma_p^2) * [\hat{\theta}_{hj}]_{MAP}$$

\mathcal{N} denota la curva normal o gaussiana

$$y \mu_p = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \left[\frac{\mu_0}{\sigma_0^2} + \frac{\sum_{i=1}^n x^{(i)}}{\sigma^2} \right]; \sigma_p^2 = \left[\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right]^{-1}$$

$$P(\text{mujer} | \vec{x}) = \mathcal{N}_{\text{Peso}}^{(m)}(\mu_p, \sigma_p^2) * \mathcal{N}_{\text{altura}}^{(m)}(\mu_p, \sigma_p^2) * [\hat{\theta}_{mj}]_{MAP}$$

4. Con $\bar{x}_1 = (\text{Rene}, 168, 65)$ tenemos:

$$P(\text{hombre} | \bar{x}_1) = \frac{1}{\sqrt{2\pi}} \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma_p^2} \right)^{1/2} \exp \left(- \frac{\left(x - \left[\left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma_p^2} \right)^{-1} \left(\frac{\mu_{0p}}{\sigma_0^2} + \frac{547.4}{\sigma_p^2} \right) \right]^2 \right) \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma_p^2} \right)}{2} \right) * \dots$$

$$\frac{1}{\sqrt{2\pi}} \left(\frac{1}{\sigma_A^2} + \frac{n}{\sigma_A^2} \right)^{1/2} \exp \left(- \frac{\left(x - \left[\left(\frac{1}{\sigma_A^2} + \frac{n}{\sigma_A^2} \right)^{-1} \left(\frac{\mu_{0A}}{\sigma_A^2} + \frac{1237}{\sigma_A^2} \right) \right]^2 \right) \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma_A^2} \right)}{2} \right) * \dots$$

$$\frac{\alpha_k + \tau_k}{n + \sum_{k=1}^K \alpha_k}$$

pero: $\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} = \frac{\sigma^2 + n\sigma_0^2}{\sigma_0^2 \sigma^2} \Leftrightarrow \frac{1}{\sigma_0^2 + \frac{n}{\sigma^2}} = \frac{\sigma_0^2 \sigma^2}{\sigma^2 + n\sigma_0^2}$

ahora $\frac{\sigma_0^2 \sigma^2}{\sigma^2 + n\sigma_0^2} \left[\frac{\mu}{\sigma_0^2} + \frac{\sum_{i=1}^n x^{(i)}}{\sigma^2} \right] = \frac{\mu \sigma_0^2 \sigma^2}{(\sigma^2 + n\sigma_0^2) \sigma_0^2} + \frac{\sigma_0^2 \sigma^2 \sum x^{(i)}}{\sigma^2 (\sigma^2 + n\sigma_0^2)} = \frac{\mu \sigma^2}{\sigma^2 + n\sigma_0^2} + \frac{\sigma_0^2 \sum x^{(i)}}{\sigma^2 + n\sigma_0^2} = \hat{\mu}$

que ya habíamos calculado

falta calcular $\frac{\sigma_0^2 \sigma^2}{\sigma^2 + n\sigma_0^2} = \sigma_p^2$ para el peso y altura esto para simplificar los cálculos, entonces:

$$\sigma_{p, \text{Altura}}^{(h)^2} = \frac{(0.0020)(0.3)}{(0.0020) + 7(0.3)} = \frac{0.0006}{2.102} = 2.854 \times 10^{-4} = 0.0002854$$

$$\sigma_{p, \text{Altura}}^{(m)^2} = \frac{(0.1)(0.0074)}{(0.0074) + 6(0.1)} = \frac{0.00074}{0.6074} = 0.001218$$

$$\sigma_{p, \text{Peso}}^{(h)^2} = \frac{(17.0)(15.76)}{15.76 + 7(17)} = \frac{267.92}{134.76} = 1.9881$$

$$\sigma_{p, \text{Peso}}^{(m)^2} = \frac{(85.0)(71)}{71 + 6(85)} = \frac{6035.0}{581.0} = 10.387$$

Ahora sí sustituyendo valores:

$$P(\text{hombre} | \bar{x}_1) = \frac{1}{2\pi \sqrt{2.854 \times 10^{-4}}} \exp \left(- \frac{(1.68 - 1.77)^2}{2(2.854 \times 10^{-4})} \right) * \frac{1}{\sqrt{1.9881}} \exp \left(- \frac{(65 - 79)^2}{2(1.9881)} \right) * \frac{1}{6}$$

$$= 2.9923 \times 10^{-28}$$

$$P(\text{mujer} | \bar{x}_1) = \frac{1}{2\pi \sqrt{0.001218}} \exp \left(- \frac{(1.68 - 1.62)^2}{2(0.001218)} \right) * \frac{1}{\sqrt{10.387}} \exp \left(- \frac{(65 - 60)^2}{2(10.387)} \right) * \frac{2}{6} = 0.03227$$

∴ se clasifica como mujer

Con $\vec{x}_2 = (\text{Guadalupe}, 1.75, 86) \rightarrow$ Ya no perdre el paso a paso porque me canso

$$P(\text{mujer} | \vec{x}_2) = 2.207 \times 10^{-12}$$

$$P(\text{hombre} | \vec{x}_2) = 0.64$$

$\therefore \vec{x}_2$ lo clasificamos como hombre

$$\text{Con } \vec{x}_3 = (\text{Denis}, 1.80, 79)$$

$$P(\text{mujer} | \vec{x}_3) = 1.898 \times 10^{-14}$$

$$P(\text{hombre} | \vec{x}_3) = 0.394$$

$\therefore \vec{x}_3$ lo clasificamos como hombre

$$\text{Con } \vec{x}_4 = (\text{Alex}, 1.90, 85)$$

$$P(\text{mujer} | \vec{x}_4) = 3.137 \times 10^{-28}$$

$$P(\text{hombre} | \vec{x}_4) = 4.0593 \times 10^{-17}$$

$\therefore \vec{x}_4$ lo clasificamos como hombre

$$\text{Con } \vec{x}_5 = (\text{Cris}, 1.65, 70)$$

$$P(\text{mujer} | \vec{x}_5) = 0.00226$$

$$P(\text{hombre} | \vec{x}_5) = 3.0002 \times 10^{-20}$$

$\therefore \vec{x}_5$ lo clasificamos como mujer

Vemos que la clasificación en sí no cambia para ambos casos, sin embargo lo que sí cambia es $P(C | \vec{x})$ ya que se considera el MAP en este caso.

Este resultado (que la clasificación no cambie) era esperado ya que los vectores de entrada tienen tendencias muy fáciles de detectar en el caso de los hombres la altura es mayor que 1.75 que se consideraría raros en los mujeres. Lo mismo para el peso. Lo único extra a agregar es lo que ya se discutió considerar MAP hace que la categorica no sea decisiva y permita clasificar personas con un nombre específico en una clase tal que los datos de entrenamiento no contenga ese nombre tal clase un ejemplo es el caso con \vec{x}_1 donde Rene hombre no está en los datos de entrenamiento pero pasa que $P(\text{hombre} | \vec{x}_1) > 0$. Concluimos con un aprendí mucho XD